

Portfólio Gabriel Maciel

Gabriel Maciel

2022-03-06

Contents

1	Sobre Mim	5
1.1	Quem sou eu?	5
1.2	Formação	6
1.3	Experiência Profissional	6
1.4	Habilidades	8
2	Projetos	9
2.1	Banco Iris	9
2.2	Outro banco	15

Chapter 1

Sobre Mim



Olá, bem vindo ao meu portfólio de ciência de dados, nele eu vou falar um pouco sobre minha relação com estatística e ciência de dados, mostrar minhas habilidades e experiências profissionais.

E-mail: gabrielmacieldias@hotmail.com

Celular: (31) 98905-9541

1.1 Quem sou eu?

Meu nome é Gabriel Maciel Dias, tenho 23 anos e moro na cidade de Belo Horizonte.

Ingressei no curso de Estatística na UFMG em 2017 através do Enem, onde tive o primeiro contato com o mundo dos dados, desde então venho aprendendo sobre ciência de dados e como ela pode resolver problemas de diversas áreas.

Durante minha trajetória na graduação passei por estágios em diferentes áreas, comecei com uma rápida passagem no Hospital Odilon Behrens, no qual fazia análises voltada para saúde, em seguida fiz a transição para a própria UFMG, trabalhando como estagiário na Prograd fazendo grandes relatórios internos e públicos para avaliar qual é o desempenho dos docentes da UFMG, bem como o perfil dos ingressantes pelo SiSU.

Depois desses estágios comecei minha carreira na área de crédito, iniciei no Banco BDMG onde vi os primeiros modelos de risco, modelagem de perda e estudos de fraude voltados para pessoa jurídica. Trabalhei também no Banco BS2, vendo novamente os modelos de crédito para pessoa jurídica e também para pessoa física, lá tive mais contato com os desenvolvedores que criavam as APIs e engenheiros de dados que preparavam os bancos de dados para as análises.

Atualmente trabalho como Assistente de Crédito no Banco Seara, no qual posso ter ainda mais contato com as análises e modelos de créditos, aprendendo diariamente sobre a parte operacional e teórica do crédito.

1.2 Formação

Bacharel em Estatística na Universidade Federal de Minas Gerais (UFMG) 2017 - 2021

1.3 Experiência Profissional

Desde que comecei na graduação passei por alguns estágios em áreas diferentes. Atualmente trabalho como Assistente de Crédito no Banco Seara e também como cientista de dados na startup Sua Rua.

1.3.1 Hospital Odilon Behrens

Cargo: Estagiário de Estatística - Abril/2018 à Outubro/2018

Responsável pela confecção de relatórios mensais, além do atendimento de demanda de dados, fazendo a retirada deles em um banco específico do hospital. Durante esse período de trabalho elaborei alguns códigos na linguagem de programação R com o objetivo de aperfeiçoar relatórios e análises de dados.

1.3.2 Prograd UFMG

Cargo: Estagiário no Setor de Estatística da Prograd UFMG - Novembro/2018 à Junho/2020

Responsável pela elaboração de relatórios com análises descritivas e modelos de regressão, com finalidade de analisar o perfil e o desempenho dos estudantes da UFMG e divulgar o resultado em sites da universidade. Além disso, eram atendidos demandas de dados feitas por funcionários da universidade. Neste período os relatórios foram feitos usando o software R em conjunto com o R Markdown, Latex e excel.

1.3.3 Banco de Desenvolvimento de Minas Gerais - BDMG

Cargo: Estagiário de Crédito – Julho/2020 à Dezembro/2020

Responsável pela conferência de planilhas de classificação de risco e criação de programa em R para automatizar determinadas conferências de dados. Além disso, também faço trabalhos com simulações (em Python e R) de carteiras de crédito para prever possíveis perdas. Fiz a criação de um programa em R que fazia a leitura e interpretação de PDF's que verificavam possíveis anomalias, além disso, trabalhei diretamente com análise de fraude.

1.3.4 Banco BS2

Cargo: Estagiário de Crédito – Janeiro/2021 à Agosto/2021

Responsável pelos atendimentos de ordens de serviço relacionado a dúvidas sobre análise de crédito além verificar como está o andamento de uma solicitação de crédito dentro do sistema do banco. Além disso, também trabalho na confecção de relatórios Backtest em R em conjunto com R Markdown com base de dados retiradas do SQL Server para verificar como a esteira de crédito está funcionando e se ela está tomando boas decisões de previsão.

1.3.5 Banco Semear

Cargo: Assistente de Crédito - Setembro/2021 - Atualmente

Responsável por criação de dashboards para tomada de decisões usando dados de carteira e esteira de crédito. Participo de comitês de crédito, reuniões com fornecedores de dados e de modelos e reuniões com lojistas do banco. Faço também rateio e pagamento de fornecedores, estudo de base de dados para pré aprovado, bem como sugestões de análises que podem ajudar na resolução de problemas de negócio. Todas as análises faço através do software R em conjunto com o Shiny e Excel.

1.3.6 Sua Rua

Cargo: Cientista de Dados - Agosto/2021 - Atualmente

Nessa startup trabalho com construção de modelos de dados geográficos, trabalhando com R e QGis, além disso atuo coletando dados e criando robôs para fazer Web Scrapping.

1.4 Habilidades

Programação avançada em R

Criação de relatórios com R Markdown

Criação de Dashboards com Shiny

Inglês intermediário

Pacote Office

Chapter 2

Projetos

Abaixo tenho alguns projetos análises de dados que fiz para treinar algumas habilidades.

2.1 Banco Iris

Para primeira análise não tinha como ser diferente, vou começar com o dataset Iris, que é uma das bases de dados mais utilizadas para fazer análises básicas.

Para verificar a estrutura do banco de dados iris podemos usar a função “head”:

```
head(iris)
```

##	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
## 1	5.1	3.5	1.4	0.2	setosa
## 2	4.9	3.0	1.4	0.2	setosa
## 3	4.7	3.2	1.3	0.2	setosa
## 4	4.6	3.1	1.5	0.2	setosa
## 5	5.0	3.6	1.4	0.2	setosa
## 6	5.4	3.9	1.7	0.4	setosa

Usando a função “head” podemos ver as primeiras linhas da base de dados e suas colunas.

Segundo o UCI Machine Learning, a base do Iris contém ao todo 150 linhas com 5 colunas, sendo:

- Sepal.Length = comprimento das sépalas (em cm);
- Sepal.Width = largura das sépalas (em cm);

- Petal.Length = comprimento das pétalas (em cm);
- Petal.Width = largura das pétalas (em cm);
- Species = espécie das plantas;

Para saber com qual análise posso começar vou verificar antes as classes das variáveis usando a função “glimpse” do pacote “dplyr”.

```
library(dplyr)
```

```
glimpse(iris)
```

```
## Rows: 150
## Columns: 5
## $ Sepal.Length <dbl> 5.1, 4.9, 4.7, 4.6, 5.0, 5.4, 4.6, 5.0, 4.4, 4.9, 5.4, 4.~
## $ Sepal.Width <dbl> 3.5, 3.0, 3.2, 3.1, 3.6, 3.9, 3.4, 3.4, 2.9, 3.1, 3.7, 3.~
## $ Petal.Length <dbl> 1.4, 1.4, 1.3, 1.5, 1.4, 1.7, 1.4, 1.5, 1.4, 1.5, 1.5, 1.~
## $ Petal.Width <dbl> 0.2, 0.2, 0.2, 0.2, 0.2, 0.4, 0.3, 0.2, 0.2, 0.1, 0.2, 0.~
## $ Species <fct> setosa, setosa, setosa, setosa, setosa, setosa, setosa, s~
```

Sabendo que as classes são numéricas vou utilizar o “summary” para uma visão geral.

```
summary(iris[,1:4])
```

```
##   Sepal.Length   Sepal.Width   Petal.Length   Petal.Width
## Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
## 1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
## Median :5.800   Median :3.000   Median :4.350   Median :1.300
## Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
## 3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
## Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
```

Ao analisar os resultados pode-se notar que o comprimento das sépalas e pétalas é maior do que a largura dos mesmos.

Após observar brevemente o banco Iris gostaria de responder as seguintes perguntas:

- O tamanho de sépala e as espécies influenciam no tamanho de pétala?
- Se sim, qual é essa relação?

2.1.1 Análise descritiva

Para responder essa pergunta vou começar com análise descritivas, que podem ser simples mas que em muitos casos já conseguem identificar informações valiosas

Vou partir do pressuposto que a média entre comprimento e largura de sépalas e pétalas é um bom indicador do seu tamanho, então farei isso no R.

```
iris <- iris %>%
  mutate(media_petala = (Petal.Length+Petal.Width)/2, # Média das pétalas
         media_sepala = (Sepal.Length+Sepal.Width)/2) %>% # Média das sépalas
  select(media_petala,media_sepala,Species)

head(iris, 5)
```

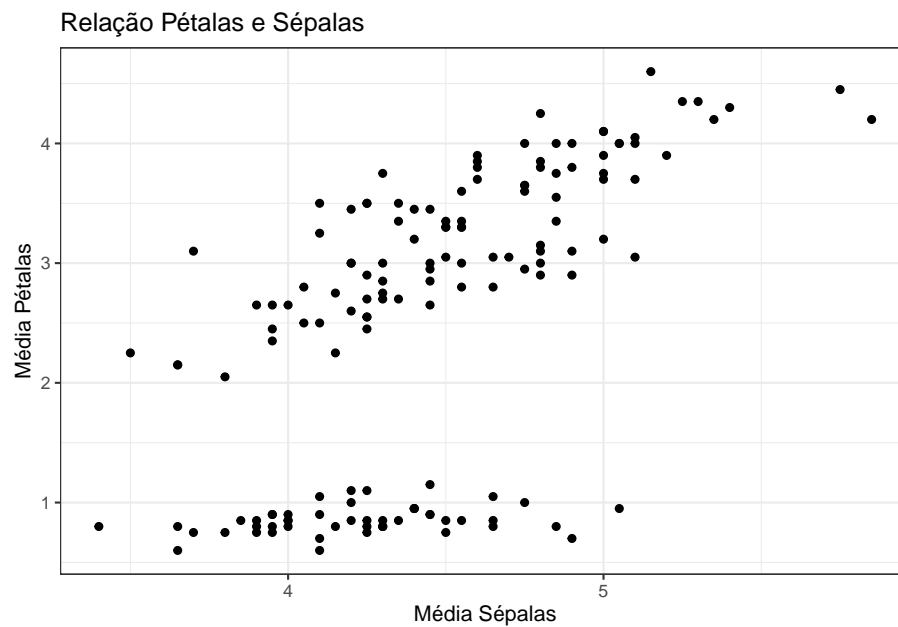
```
##   media_petala media_sepala Species
## 1         0.80         4.30  setosa
## 2         0.80         3.95  setosa
## 3         0.75         3.95  setosa
## 4         0.85         3.85  setosa
## 5         0.80         4.30  setosa
```

Podemos ver acima como ficou o banco de dados agora com apenas 3 variáveis.

Primeiramente farei um gráfico para verificar visualmente se há uma possível relação entre a média de comprimento e largura das pétalas e sépalas.

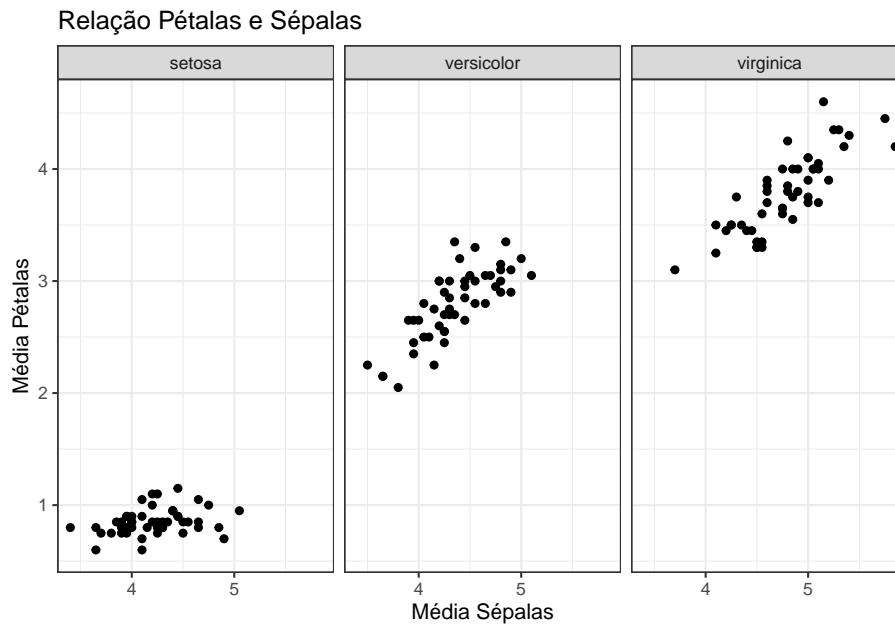
```
library(ggplot2)

ggplot(iris) +
  geom_point(aes(x = media_sepala,y = media_petala)) +
  labs(title = "Relação Pétalas e Sépalas",
       x = "Média Sépalas",
       y = "Média Pétalas") +
  theme_bw()
```



É possível notar que parece existir alguma relação, porém o efeito das espécies não nos permite enxergar essa relação, então vou segmentar meu gráfico de acordo com a espécie.

```
ggplot(iris) +  
  geom_point(aes(x = media_sepala, y = media_petala)) +  
  labs(title = "Relação Pétalas e Sépalas",  
       x = "Média Sépalas",  
       y = "Média Pétalas") +  
  theme_bw() +  
  facet_grid(~ Species)
```



Agora podemos notar que as espécies parecem influenciar no tamanho das pétalas e sépalas, visto que os pontos se encontram em locais distintos dos gráficos. Além disso, nota-se possível relação positiva entre tamanho de sépalas e pétalas nas espécies versicolor e virginica, já a setosa não apresenta graficamente essa relação.

2.1.2 Análise de Regressão

Para avaliar se realmente existe essa relação estatística entre as pétalas, sépalas e espécie de planta eu vou usar a técnica de regressão, que é robusta e nos ajuda em diversas situações.

```
# Usando a função lm para ajustar o modelo

fit <- lm(media_petala~media_sepala+Species, data = iris)

# Usando a função summary para avaliar resultados dos ajustes

summary(fit)

##
## Call:
## lm(formula = media_petala ~ media_sepala + Species, data = iris)
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.50872 -0.13092  0.00096  0.14311  0.61936
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -1.33611     0.18761  -7.122 4.49e-11 ***
## media_sepala      0.51935     0.04398  11.809 < 2e-16 ***
## Speciesversicolor  1.86837     0.04055  46.073 < 2e-16 ***
## Speciesvirginica   2.64209     0.04716  56.025 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2005 on 146 degrees of freedom
## Multiple R-squared:  0.9749, Adjusted R-squared:  0.9744
## F-statistic: 1893 on 3 and 146 DF,  p-value: < 2.2e-16
```

Acima temos alguns resultados interessantes, primeiramente é possível notar que o tamanho médio das sépalas e a espécie influencia no tamanho médio das pétalas, chego nessa conclusão pois o p-valor do modelos para cada um das variáveis é menor que 0,05.

A cada unidade que aumentamos no tamanho médio das sépalas, 0,51 é adicionado no tamanho médio das pétalas. Já quanto as espécies, o tamanho das pétalas na espécie Versicolor é 1,86 vezes maior que na espécie Setosa (que está oculto nos resultados) enquanto as pétalas na espécie Virginica é 2,64 vezes maior que na Setosa.

Além disso temos o resultado ajustado o R^2 de 0,9744, isso indica que aproximadamente 97% da variação do tamanho das pétalas é explicada pelo tamanho das sépalas e a espécie.

Antes de chegar a uma conclusão final dos resultados devemos verificar algumas suposições. Para o modelo de regressão polinomial é necessário normalidade e homocedasticidade dos resíduos.


```
# Teste de normalidade de Shapiro Wilk
```

```
shapiro.test(fit$residuals)
```

```
##
## Shapiro-Wilk normality test
##
## data:  fit$residuals
## W = 0.99395, p-value = 0.7868
```

O p-valor do teste de Shapiro Wilk foi de 0,7868, dessa forma concluímos que os resíduos seguem a distribuição normal.

```
# Verificação de homocedasticidade  
plot(fit$fitted.values,fit$residuals)
```



Acima temos o gráfico dos resíduos pelo valores ajustados, a dispersão dos resíduos ao longo do eixo dos valores ajustados parece ser a mesma, esse é um grande indicativo de homocedasticidade dos resíduos, ou seja, variância constante.

2.1.3 Conclusão

Após essa análise podemos responder as questões propostas no início do estudo.

O tamanho de sépala e tipo de espécie influenciam sim no tamanho das pétalas, e essa relação acontece da seguinte forma:

- O tamanho de sépala tem uma relação positiva com o tamanho das pétalas, ou seja, quanto maior são as sépalas, maiores vão ser as pétalas.
- Além disso, as espécies Virginica e Versicolor apresentam influenciam com tamanho de pétala maior em relação as plantas da espécie Setosa.

2.2 Outro banco